

LLM для анализа сетевого трафика

Классификация Normal / DDoS на IoT-датасете

Зачётное задание по курсу «Безопасность инфраструктурных технологий»

Весна 2026

Постановка задачи

Исследовательский вопрос

Можно ли с помощью русскоязычного промпта получить корректное Jupyter Notebook-приложение для классификации вредоносного сетевого трафика?

- Сгенерировать код минимум в нескольких LLM.
- Сравнить LLM-решения с ручной моделью.
- Оценить не только метрики, но и методологию.

Критерии качества

Работоспособность **код запускается**

ML-методология **нет утечек**

Метрики **macro-F1, balanced accuracy**

Воспроизводимость **result.csv, модели**

Датасет

DDoSdata.csv

Строк	1 927 101
Признаков	47
DDoS	1 926 624
Normal	477
Доля Normal	□ 0.025%

Главная сложность: экстремальный дисбаланс классов.

Группы признаков

- статистика потока: pkts, bytes, rate;
- время: stime, ltime, dur;
- адреса и порты: saddr, daddr, sport;
- разметка: attack, category, subcategory.

Модель, написанная человеком

MLP на PyTorch

- target: attack;
- split: 70% / 15% / 15%;
- SMOTE только на train;
- StandardScaler;
- архитектура: input → 128 → 64 → 32 → classes.

Результат

Train до SMOTE	1 348 970
Train после SMOTE	2 697 272
Test size	289 066
Accuracy	100.00%
F1 по классам	1.00 / 1.00

Важно: ручная модель использует attack, поэтому сравнение с LLM по category не полностью эквивалентно.

Суть русскоязычного промпта

«Ты — Data Scientist. Нужно создать Python-приложение в формате Jupyter Notebook для классификации сетевого трафика на Normal и DDoS. Датасет содержит признаки ... attack, category, subcategory. Целевая переменная — category. Есть критический дисбаланс: около 2 млн DDoS и около 500 Normal. Напиши код блоками: загрузка, анализ, подготовка, обработка дисбаланса, обучение минимум двух моделей, оценка, матрица ошибок и сохранение result.csv.»



Чёткая цель
Normal / DDoS



Указан дисбаланс
важно для метрик



Нужен контроль
LLM ошибаются в
методологии

Что сгенерировано

- target: category;
- удалены явные признаки-утечки;
- RandomUnderSampler 1:10;
- Random Forest и LightGBM;
- сохранение results.csv.

Результат и проблема

DDoS после undersampling **4 770**

Normal после undersampling **477**

Random Forest Macro-F1 **1.00**

LightGBM Macro-F1 **1.00**

 Under-sampling выполнен **до** train/test split.

Итог: рабочий код, но тест стал искусственно сбалансированным, поэтому метрики слишком оптимистичны.

Плюсы

- target: category;
- Logistic Regression и Random Forest;
- under-sampling только train;
- ROC-AUC и сохранение `result.csv`.

Метрики и риски

Модель	Macro-F1	ROC-AUC
LogReg	0.99	1.00
Random Forest	0.98	1.00



В признаках оставлен
attack: риск прямой утечки.

Что получилось

- target: category;
- Logistic Regression и Random Forest;
- RandomUnderSampler до split;
- итоговый набор: 477 / 477;
- обе модели показали 1.00 по метрикам.

Почему результат ненадёжен

- тест всего 191 строка;
- тест искусственно сбалансирован;
- возможны признаки-утечки attack и subcategory;
- идеальные метрики не доказывают переносимость.

Вывод: простой промпт даёт рабочий каркас, но хуже контролирует ML-риски.

Методология

- target: category;
- удалены attack, subcategory, category;
- удалены ID, адреса и порты;
- сначала split, затем under-sampling только train;
- тест сохранён в реальном дисбалансе.

Лучшие метрики

Модель	Macro-F1	Bal. acc.
RF RUS	0.9703	0.999984
SGD	0.9703	0.999984
HGB RUS	0.9634	0.999981

Normal-класс

Precision: 0.8879; Recall: 1.0000

Итог: наиболее корректная ML-методология среди LLM-решений.

Сравнение всех решений

Решение	Target	Лучший результат	Методологическая оценка
Handmade	attack	accuracy 1.00	сильная модель, но другая целевая переменная
ChatGPT	category	macro-F1 0.9703	✅ наиболее корректный порядок и честный тест
Gemini	category	macro-F1 1.00	⚠️ рабочий код, но оценка оптимистична
YandexGPT	category	macro-F1 0.99	⚠️ риск утечки через attack
Yandex Simple	category	macro-F1 1.00	❌ слишком маленький и искусственно сбалансированный тест
Методологический лидер: ChatGPT.			

Главные ошибки, которые допускают LLM

1. Resampling до split

 Тест перестаёт отражать реальный дисбаланс, а метрики становятся завышенными.

2. Утечка target

 В признаках остаются attack, subcategory или category.

3. Неверная интерпретация

При дисбалансе 99.975% / 0.025% accuracy почти бесполезна без macro-F1, balanced accuracy, precision/recall редкого класса и confusion matrix.

Главный результат

LLM способны сгенерировать рабочие Jupyter Notebook-приложения для анализа сетевого трафика, но требуют экспертной проверки методологии.

- Все LLM построили базовый пайплайн: загрузка, предобработка, обучение, метрики.
- Ключевые ошибки лежат не в синтаксисе, а в ML-дизайне: утечки, split/resampling, выбор метрик.
- Самым корректным LLM-решением оказался вариант ChatGPT.
- Идеальные метрики не означают промышленную готовность: нужны тесты на другой сети и другом временном интервале.